UNIVERSIDAD
COMPLUTENSE
MADRID

Tuberías de agregación *(Aggregation Pipelines)*

Gestión de la Información en la Web
Enrique Martín - emartinm@ucm.es
Grados de la Fac. Informática

Tuberías de agregación

- Las **tuberías de agregación** *(aggregation pipelines)* son un mecanismo muy potente para procesar las colecciones aplicando varias **etapas**.
- Cada etapa recoge los datos de la etapa anterior, y su resultado es la entrada de la etapa siguiente.
- El resultado de una tubería de agregación suelen ser valores **agregados** a partir de colecciones (resúmenes, combinaciones, etc.)

Tuberías de agregación

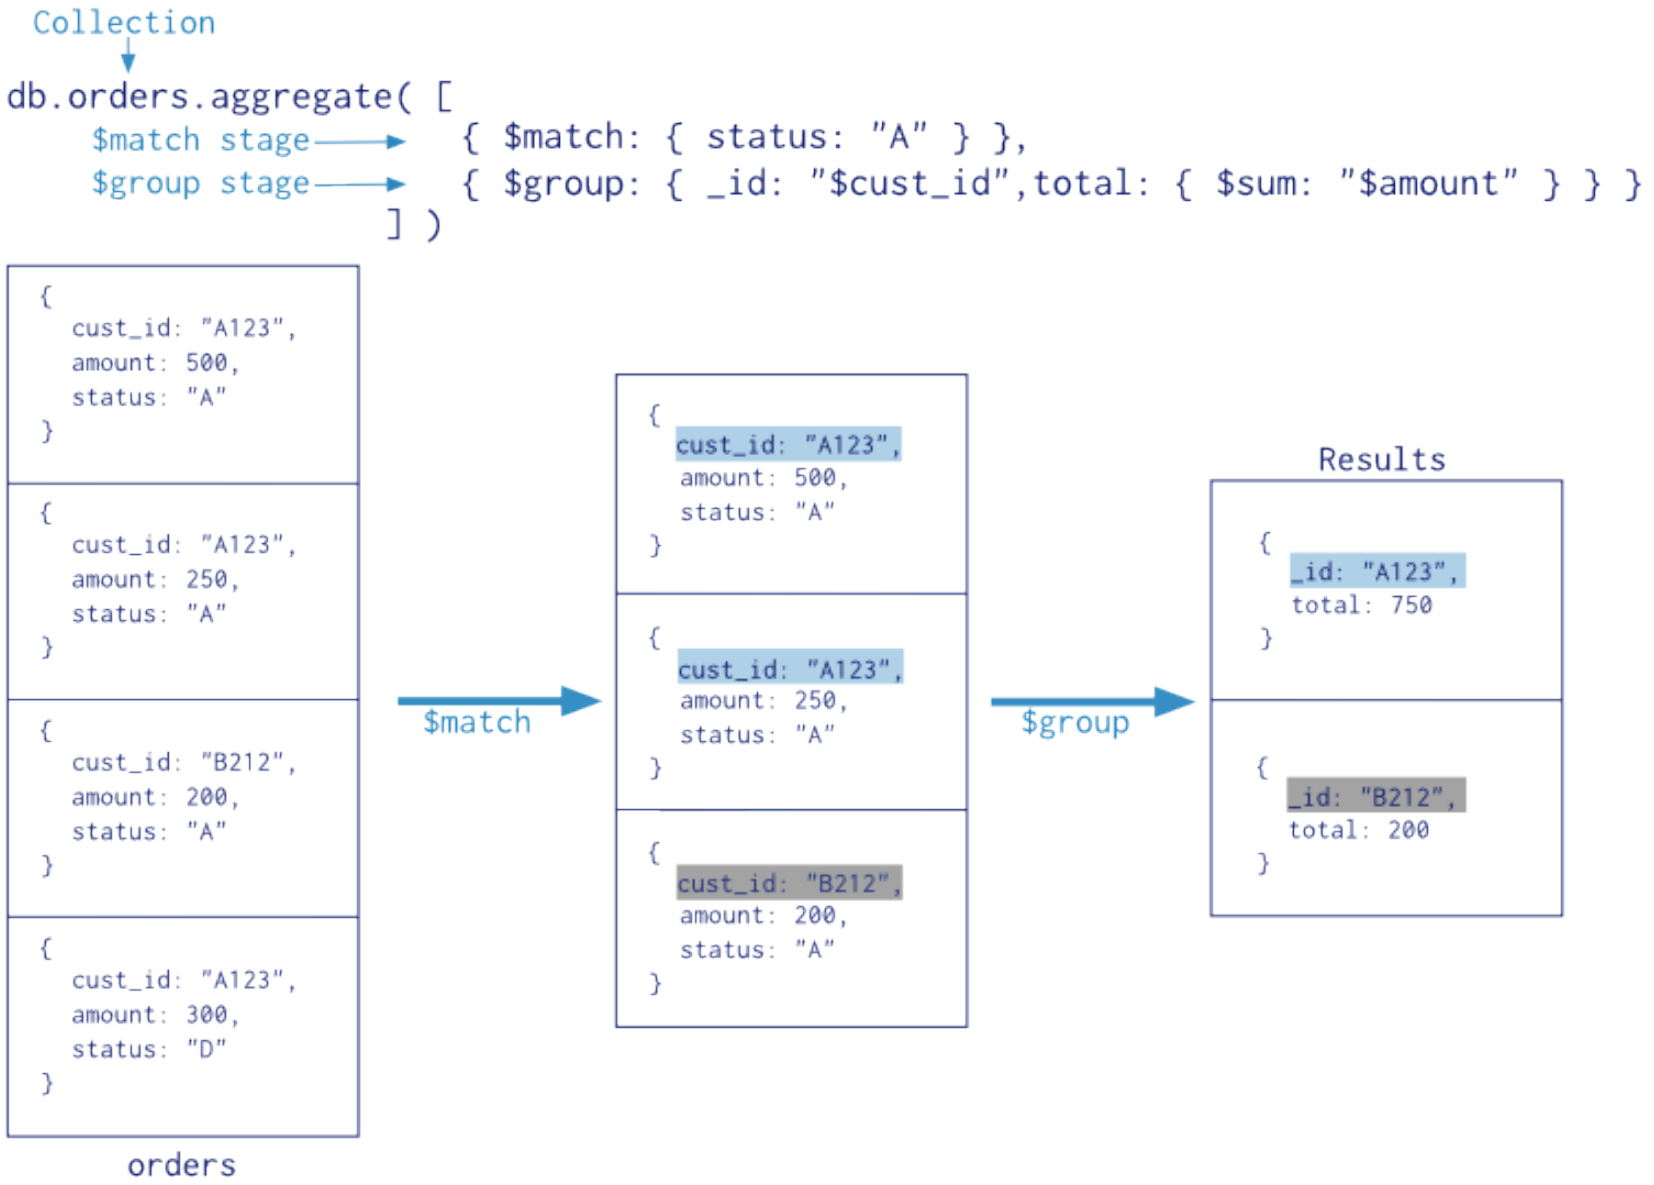

Etapas

- Las tuberías de agregación pueden tener cualquier número de etapas.
- El programador configura la secuencia de etapas a aplicar mediante documentos JSON.
- El **resultado** de una tubería de agregación se puede volcar en una **nueva colección**, o devolver un cursor como si se tratase de una consulta común.
- En las **colecciones intermedias** no es necesario garantizar que el campo **_id** sea único.

Lanzar una tubería de agregación

- Las tuberías de agregación se lanzan con el comando **aggregate** a partir de una colección:

  db.collection.**aggregate**([etapa$_1$, …, etapa$_n$])

- El comando **aggregate** recibe una lista de documentos **etapa$_1$, …, etapa$_n$** que definen el **orden** y la **configuración** de cada una de las etapas.

Tipos de etapas

- Existen más de 20 tipos diferentes de etapas que se pueden utilizar (más información en las referencias).
- Veremos con detalle únicamente algunas de ellas:
  - $project
  - $match
  - $sort
  - $limit, $skip
  - $unwind
  - $group, $lookup
  - $out

Etapas

$project

- La etapa **$project** sirve para **eliminar o añadir campos** a los documentos, es decir, reestructurar documentos.
- La etapa $projecto se define con la siguiente sintaxis:
  { $project: { <proyección> **} }**
- **<proyección>** es una serie de parejas:
  - **<campo>: <1 o true>** → 'campo' es incluido. Por defecto ningún campo se incluye si no se expresa explícitamente, salvo _id.
  - **_id: <0 o false>** → No incluir el campo _id, que por defecto siempre se incluye.
  - **<campo>: <expresión>** → Añadir un nuevo campo o restablecer el contenido de un campo existente.

Ejemplo de $project

- Quedarse únicamente con el campo **age:**

```
db.agg.aggregate([
   {$project : {_id:0, age:1}}
])
```

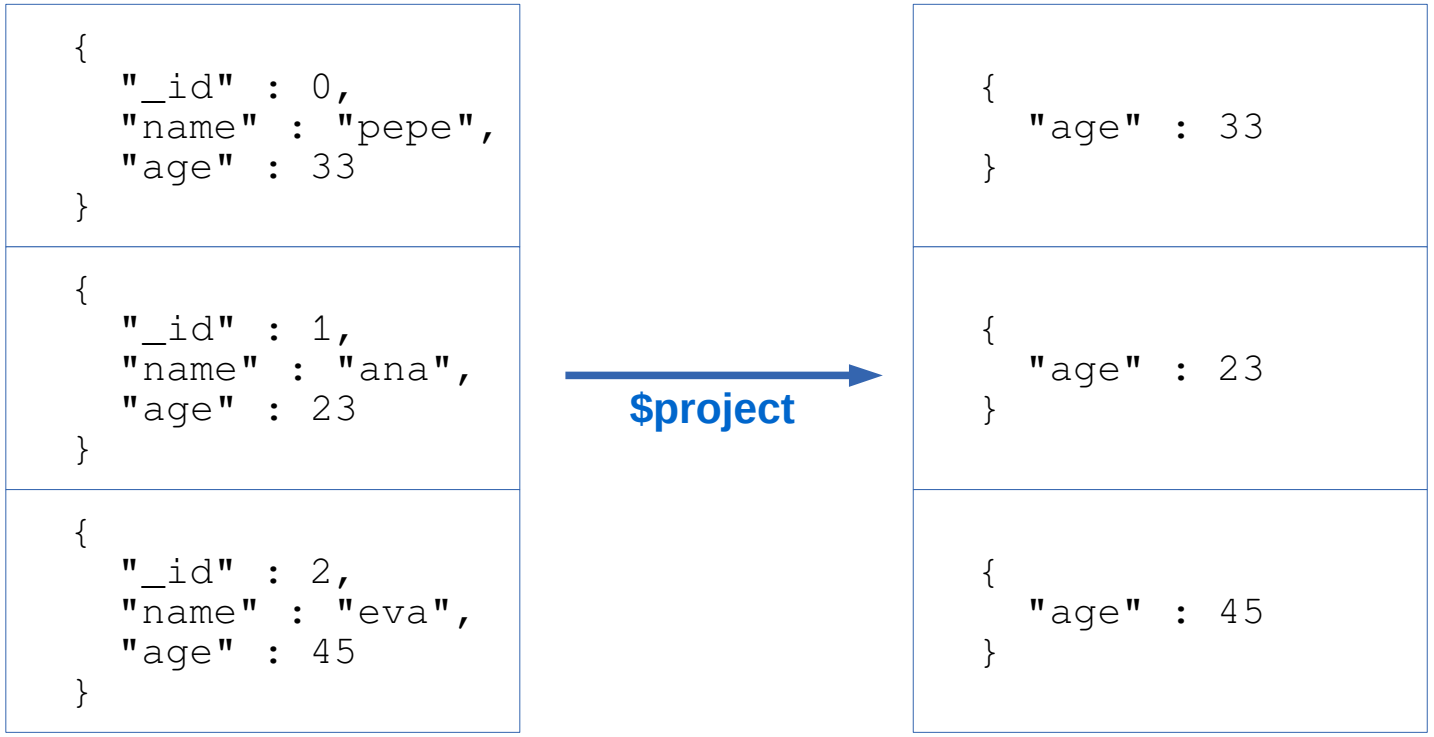

Ejemplo de $project

- Renombrar el campo **age** a **edad** y ocultar **name**:

```
db.agg.aggregate([
   {$project : {edad:'$age'}}
])
```

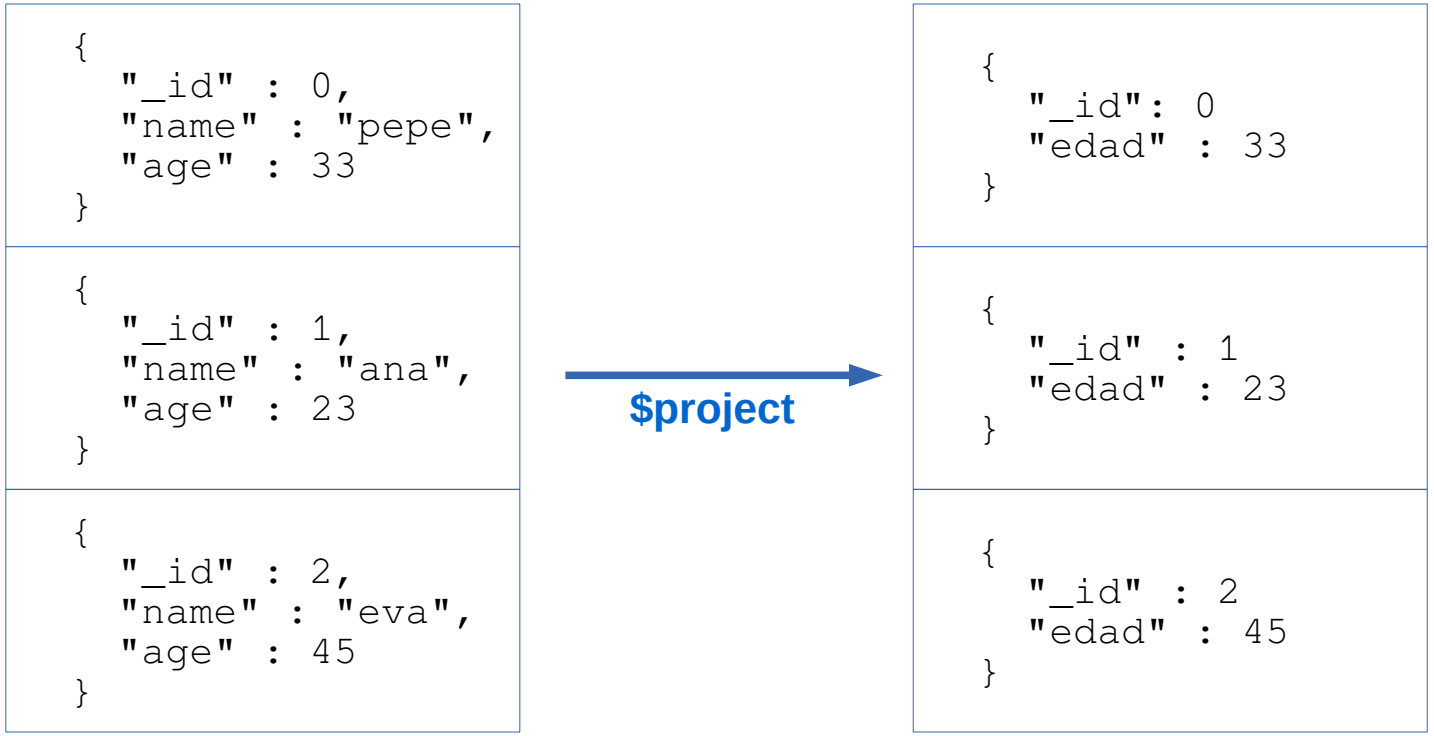

Ejemplo de $project

- **Aumentar en 1 año** el campo **age** de cada documento:

```
db.agg.aggregate([
   {$project : {age:{$add:['$age',1]}, name:1}}
])
```

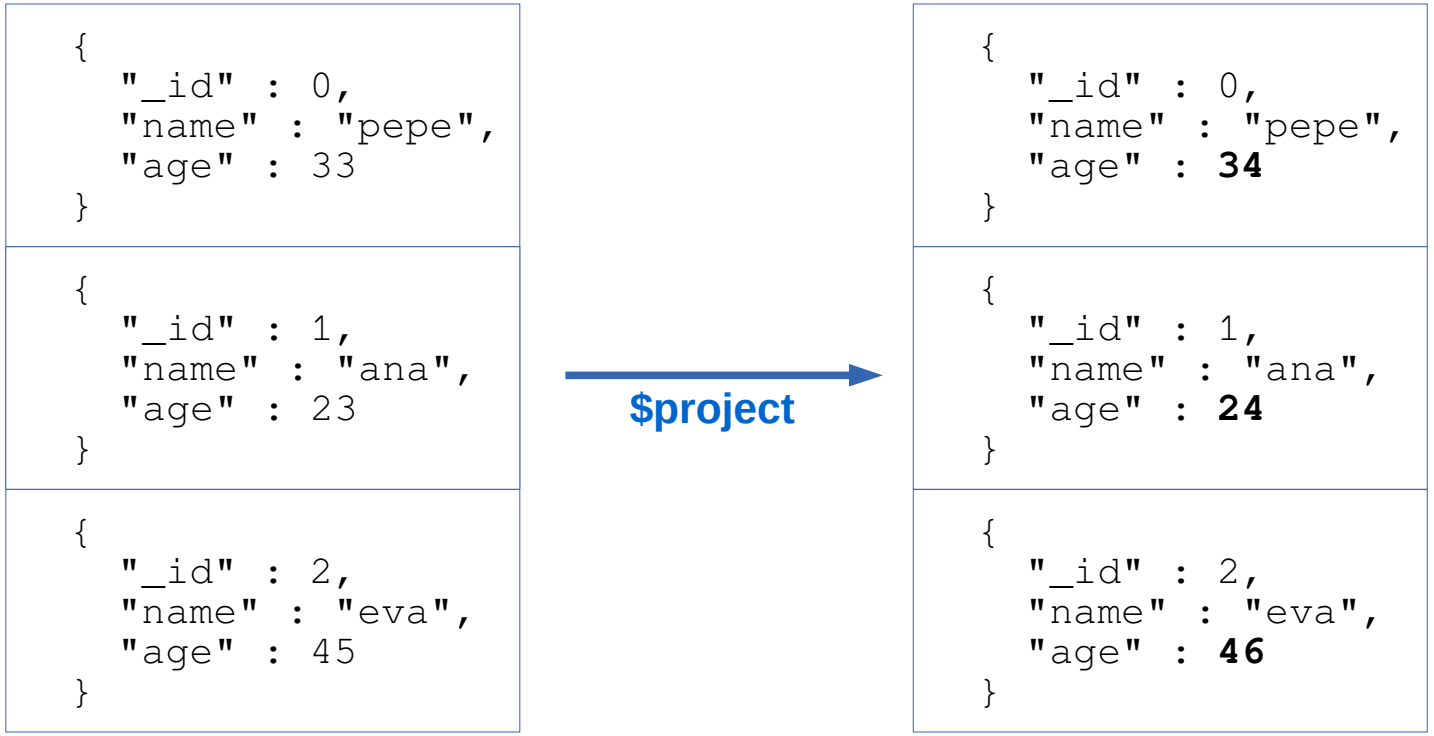

$match

- La etapa **$match filtra** los documentos, dejando pasar únicamente aquellos que cumplen una cierta **propiedad**.
- La sintaxis de la etapa $match es:
  { $match: { <propiedad> } }
- **<propiedad>** es una condición representada de la misma manera que las usadas en find().

Ejemplo de $match

- Filtrar los documentos cuya **edad** es **23** :

```
db.agg.aggregate([
   {$match : {age:23}}
])
```

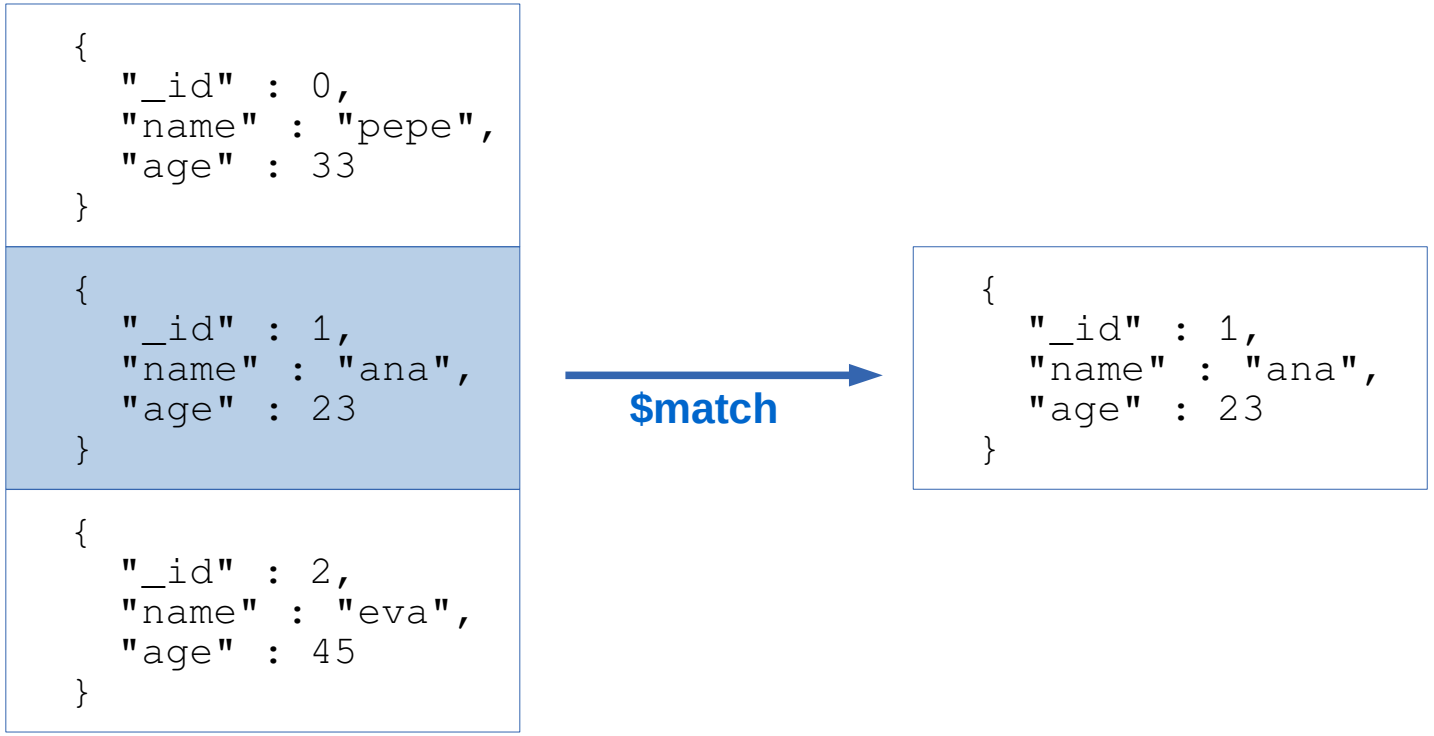

Ejemplo de $match

- Filtrar los documentos con **edad superior a 28** años:

```
db.agg.aggregate([
   {$match : {age:{$gt:28}} }
])
```

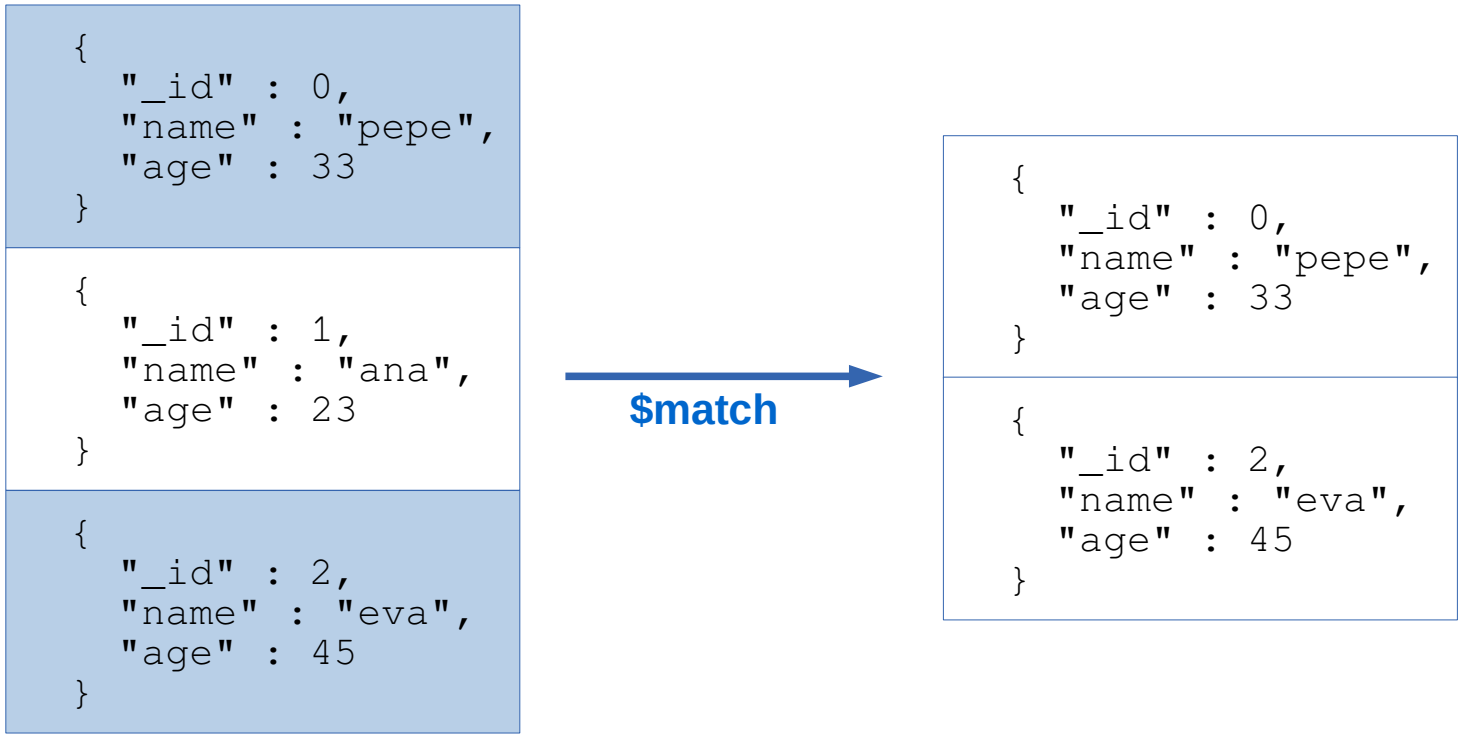

Ejemplo de $match

- Filtrar los documentos que tienen **edad inferior** a **30** años o se llaman **“eva”**:

```
db.agg.aggregate([
   {$match: {$or: [{age:{$lt:30}},{name:"eva"}] }}
])
```

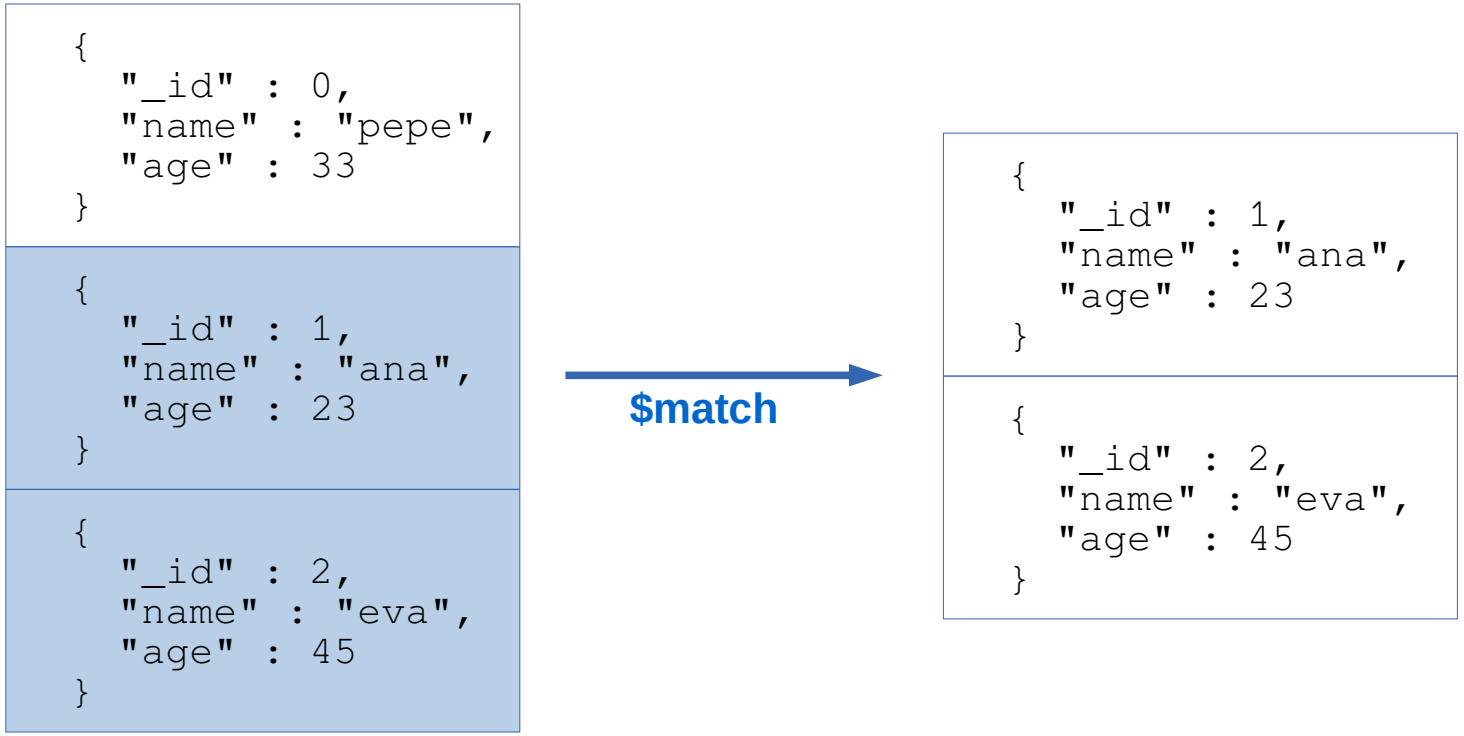

Optimizar con $match

- La etapa $match **reduce** el número de documentos a aquellos que cumplen la propiedad.
- Por ello es interesante colocar $match **lo antes posible** dentro de la tubería:
  - Las **etapas siguientes** serán más rápidas pues manejarán **menos documentos**.
  - Al ejecutarse al inicio, es más posible que $match saque provecho de los **índices**.

$sort

- **Ordena** los documentos recibidos, de acuerdo al orden pasado como parámetro.
- La sintaxis de la etapa $sort es:
  { $sort: <orden> **}**
- **<orden>** es un documento con información de orden representada de la misma manera que la usadas en sort().

Ejemplo de $sort

- Ordenar los documentos por **edad ascendente**:

```
db.agg.aggregate([
   {$sort : {age:1}}
])
```

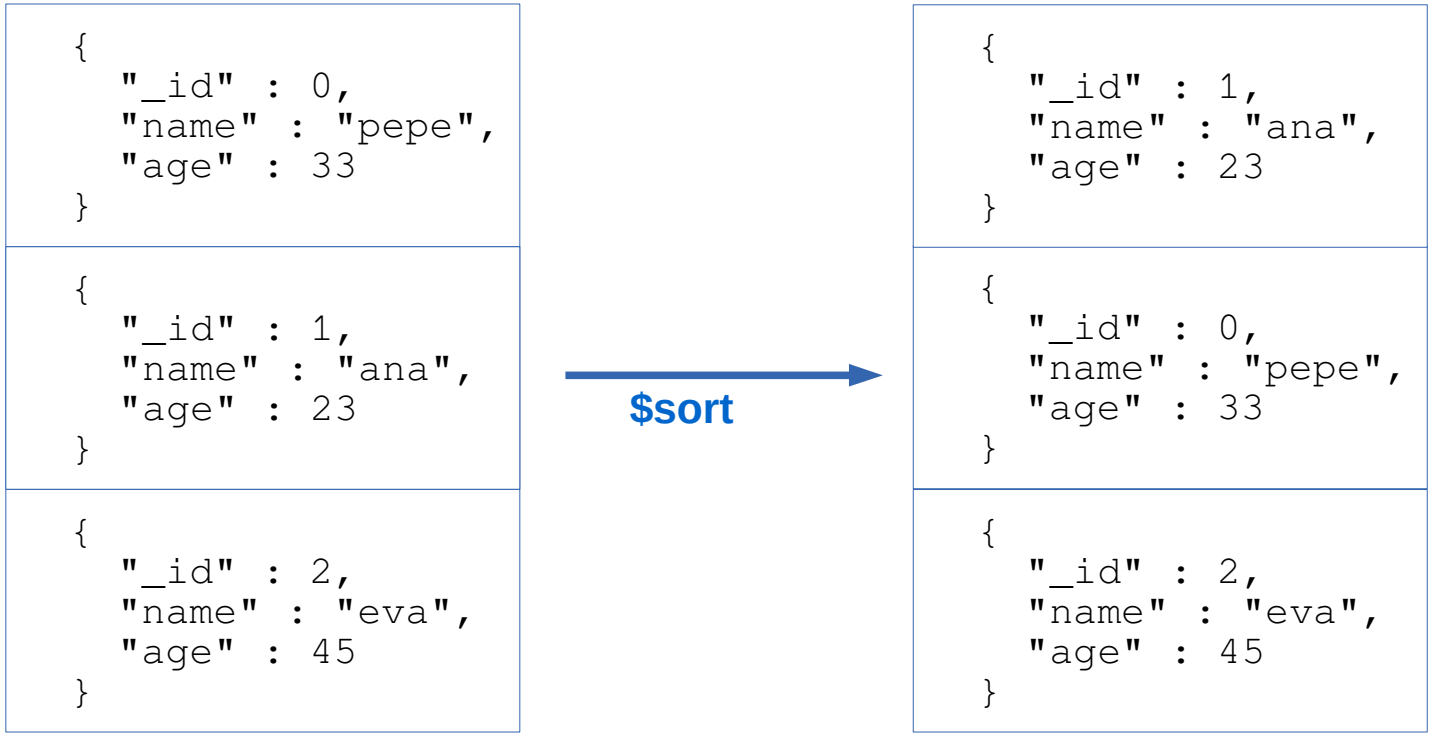

Ejemplo de $sort

- Ordenar los documentos por **nombre descendente**, y luego por **_id ascendente**:

```
db.agg.aggregate([
   {$sort : {name:-1, _id:1}}
])
```

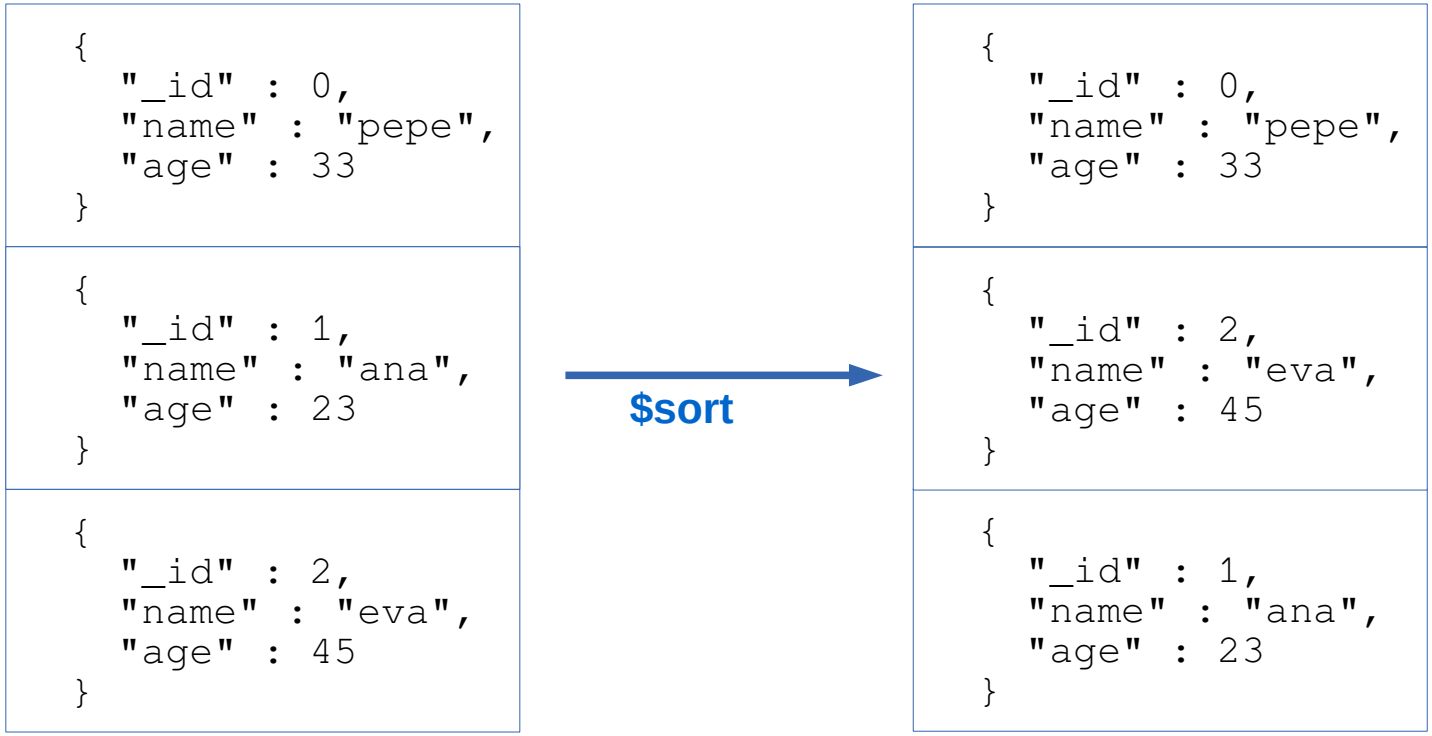

$limit

- La etapa $limit sirve para limitar a un número fijo la cantidad de documentos que pasan a la siguiente etapa.
- La sintaxis de la etapa $limit es:
  { $limit: <entero positivo> **}**
- **<entero positivo>** es cualquier número entero mayor que 0.

Ejemplo de $limit

- Limitar la salida a **2 documentos**:

```
db.agg.aggregate([
    {$limit : 2}
])
```

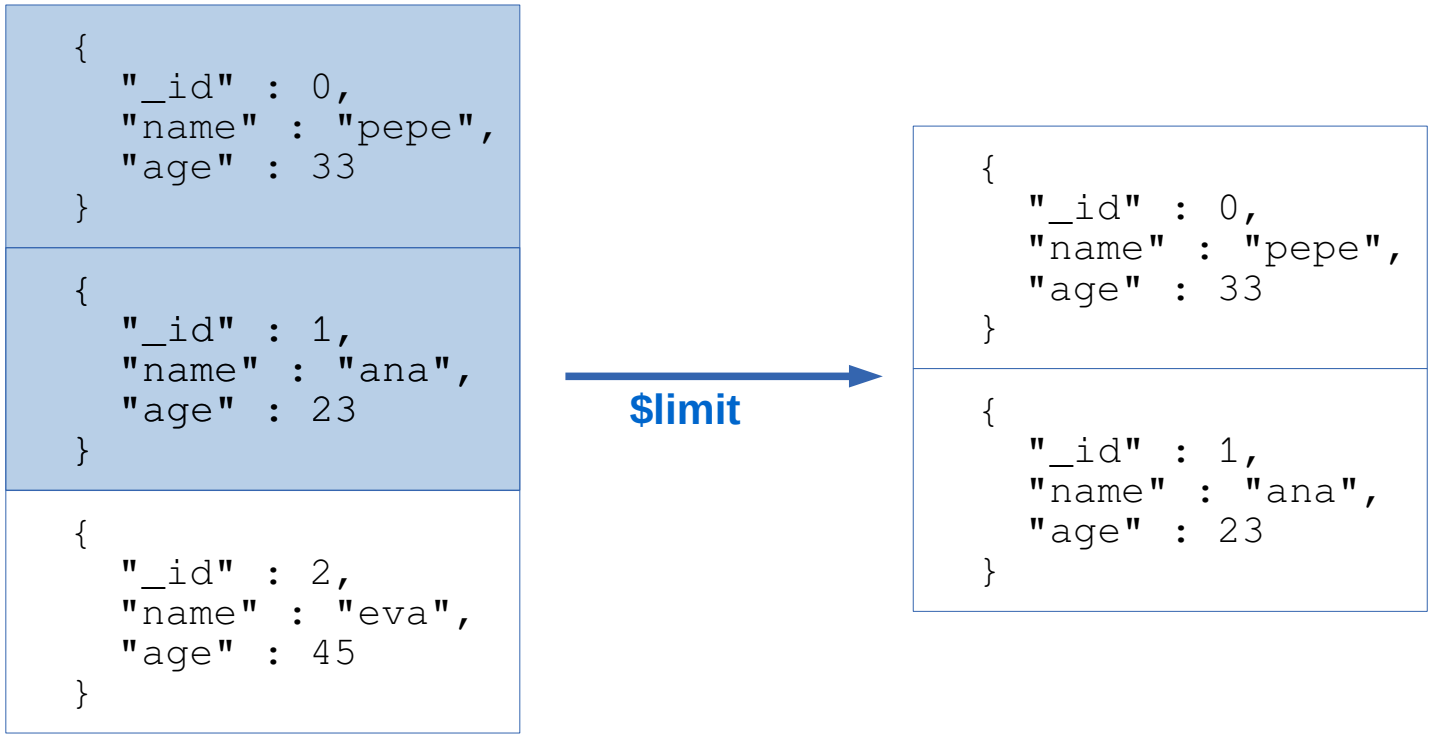

$limit y $sort

- $limit devuelve los **primeros** '**n**' documentos de entrada, respetando el orden que éstos tienen.
- Si se encadena una etapa **$sort** y justo después una etapa **$limit**, MongoDB **optimizará** la etapa $sort:
  - Durante la ordenación ($sort) MongoDB únicamente almacenará **'n' resultados** en memoria.

$skip

- La etapa $skip **descarta** los primeros '**n**' **documentos** de entrada y devuelve el resto.
- La sintaxis de la etapa es:
  { $skip: <entero positivo> **}**
- **<entero positivo>** es cualquier número entero mayor o igual que 0.

Ejemplo de $skip

- **Descartar** el **primer** documento:

```
db.agg.aggregate([
    {$skip : 1}
])
```

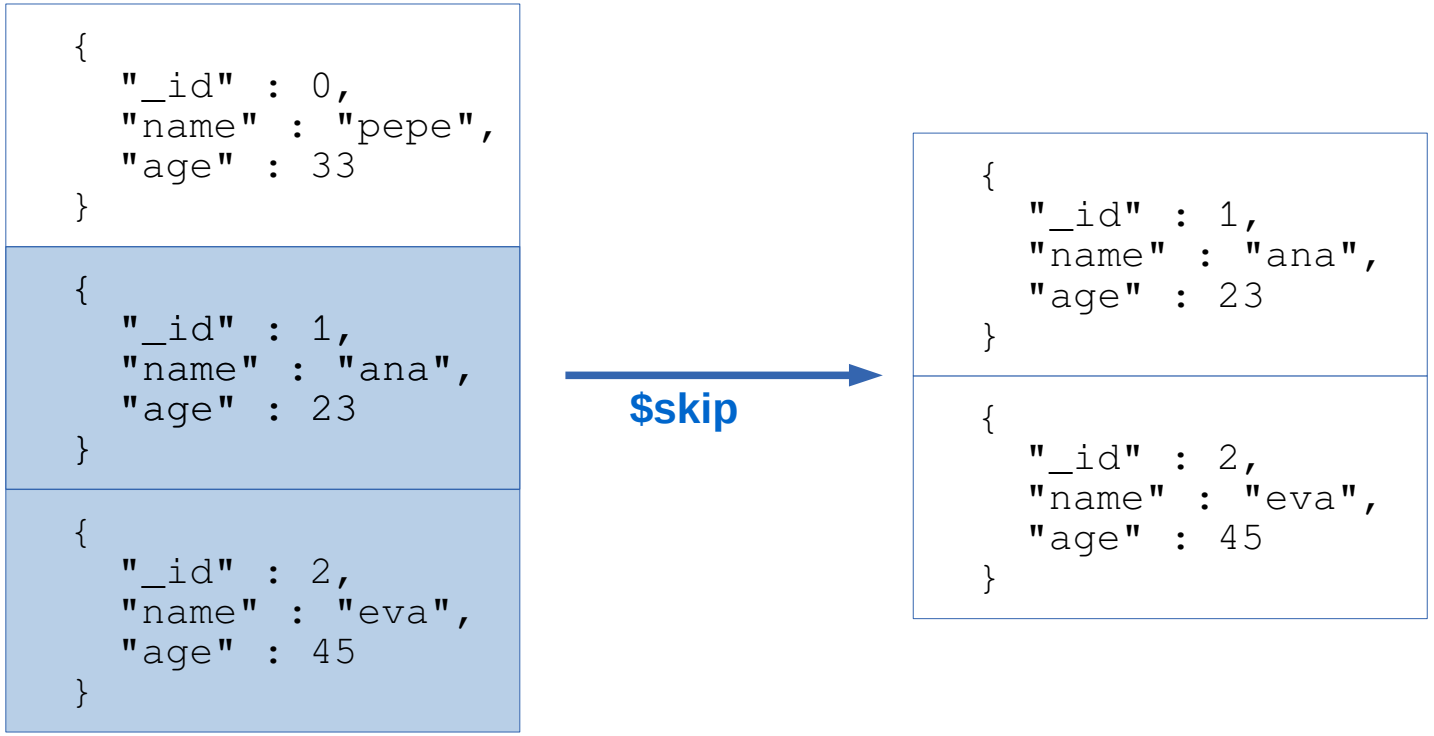

$unwind

- La etapa $unwind **despliega** un campo que contiene una lista, generando un **documento** por **cada valor de la lista**.
- La sintaxis de la etapa es:
  { $unwind: <campo> **}**
- **<campo>** es el nombre del campo que queremos usar para desplegar.

$unwind

- Dado un documento:

```
{
  _id : 0,
  state : "Spain",
  cities : ["Cádiz",
            "Valencia",
            "Sevilla"]
}
```

- Al desplegar el documento usando el campo **cities** generaríamos **3 documentos**, uno por cada valor de la lista **cities**:

```
{
  _id : 0,
  state: "Spain",
  cities: "Cádiz"
}
```

```
{
  _id : 0,
   state : "Spain",
  cities : "Valencia"
}
```

```
{
  _id : 0,
  state : "Spain",
  cities : "Sevilla"
}
```

Ejemplo de $unwind

- Desplegar por el campo **nums**:

```
db.agg.aggregate([
    {$unwind: "$nums"}
])
```

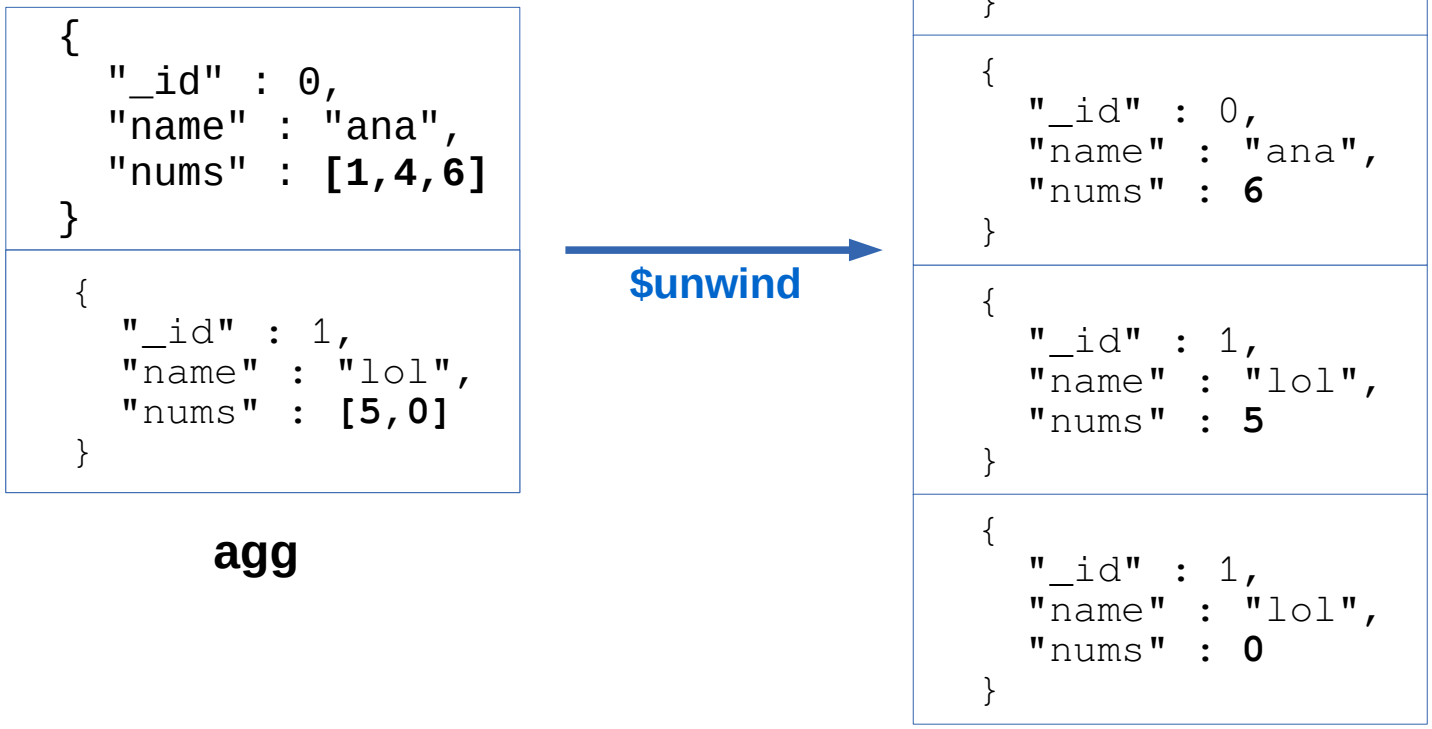

agg

Ejemplo de $unwind

- Si en algún documento el **campo** escogido para el desplegado **no contiene una lista**, se tratará como una **lista unitaria**. No lanzará **ningún error**.

```
db.agg.aggregate([
   {$unwind: "$name"}
])
```

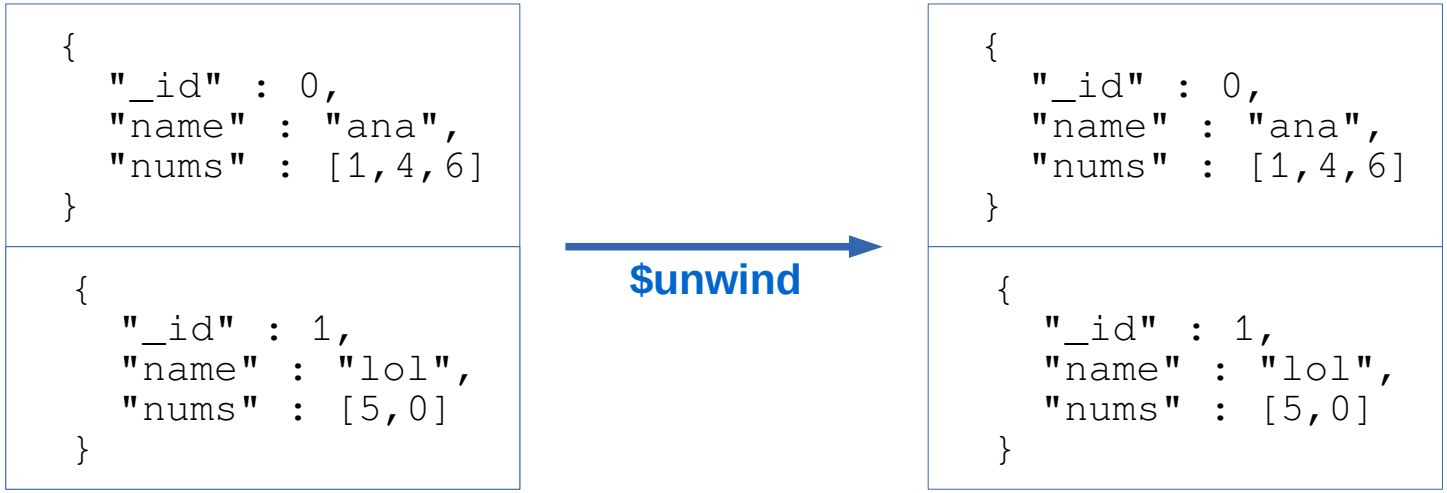

Ejemplo de $unwind

- Si en algún documento el **campo** escogido para el desplegado **no existe**, ese documento se **ignorará** pero no se lanzará **ningún error**.

```
db.agg.aggregate([
   {$unwind: "$years"}
])
```

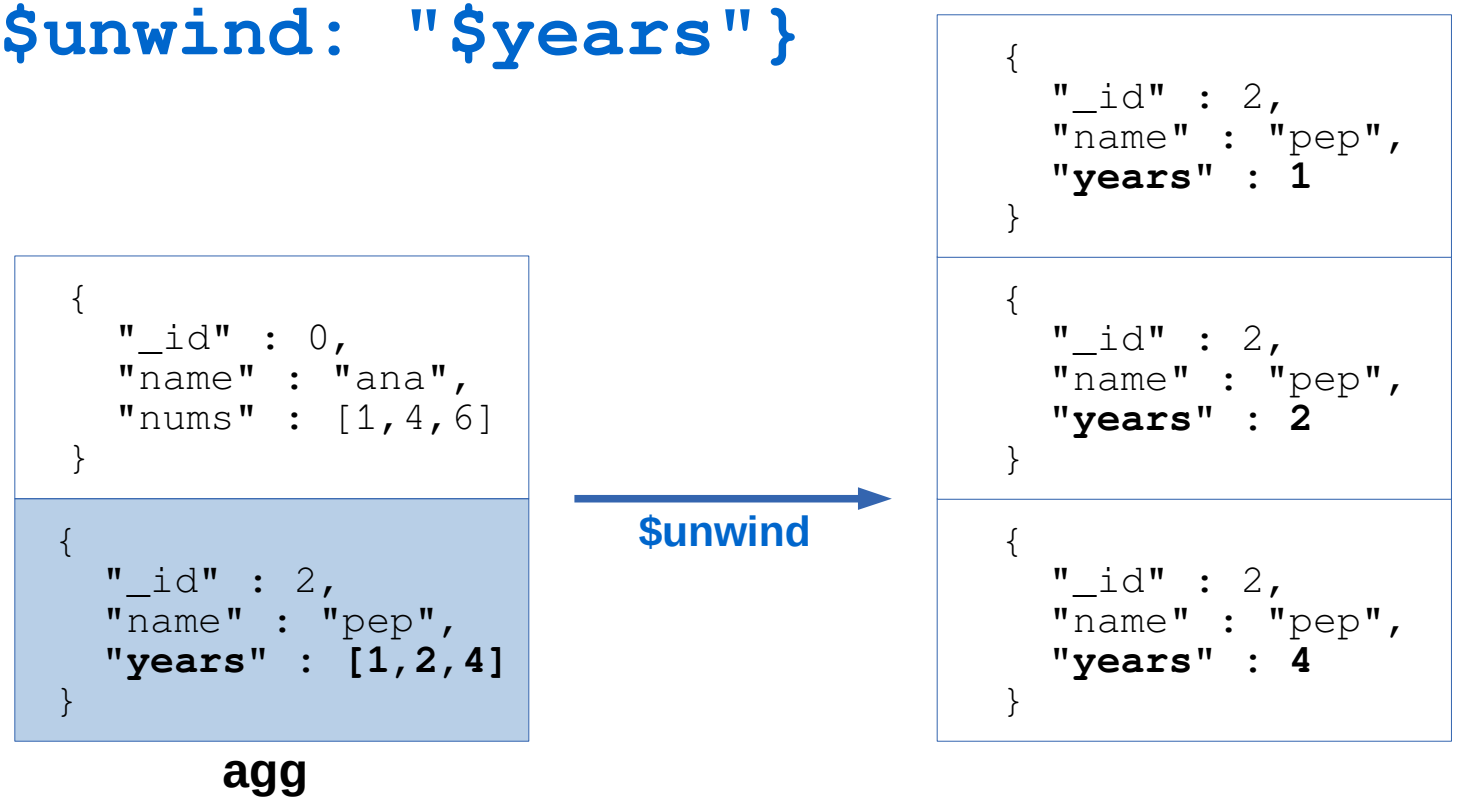

Ejemplo de $unwind

- El **campo** escogido para desplegar puede estar **anidado** dentro de otro campo.

```
db.agg.aggregate([
   {$unwind: "$likes.nums"}
])
```

agg

```
{
  "_id" : 0,
  "name" : "ana",
  "likes" : {
    "tot" : 1,
    "nums" : [1,2]
  }
}
```

```
{
  "_id" : 1,
  "name" : "eva",
  "likes" : {
    "tot" : 8,
    "nums" : [7]
  }
}
```

$unwind

```
{
  "_id" : 0,
  "name" : "ana",
  "likes" : {
    "tot" : 1,
    "nums" : 1
  }
}
```

```
{
  "_id" : 0,
  "name" : "ana",
  "likes" : {
    "tot" : 1,
    "nums" : 2
  }
}
```

```
{
  "_id" : 1,
  "name" : "eva",
  "likes" : {
    "tot" : 8,
    "nums" : 7
  }
}
```

$group

- La etapa $group **agrupa documentos** con el mismo valor en un campo (**clave**) en un solo documento.
- Este documento generado tendrá campos que **combinan** los datos de aquellos que tenían la misma clave:
  - Edad media de los usuario de España.
  - Puntuación máxima en un examen.
  - Lista de todos los usuarios de Francia.

$group

- La etapa $group tiene la sintaxis:
  { $group: { _id: <clave>**,**
  <campo1>**: {** <acumulador1> **:** <expresion1> **}, ... }**
  }
- **<clave>** es el campo o combinación de campos que se utilizará como clave.
- **<campoN>** es el nombre del campo que almacenará el valor combinado.
- **<acumuladorN>** es el operador acumulador ($sum, $avg, $max, etc.) que se usará para agregar los valores de los documentos.
- **<expresionN>** es la expresión que genera los valores que se acumularán por cada documento. Puede ser el nombre de un campo , una constante, una operación aritmética, de listas, etc.

Ejemplo de $group

- Obtener la **edad máxima** de los estudiantes por cada **Universidad:**

```
db.agg.aggregate([
    {$group: {_id: "$edu",
              max_age: {$max:"$age"} }}
])
```

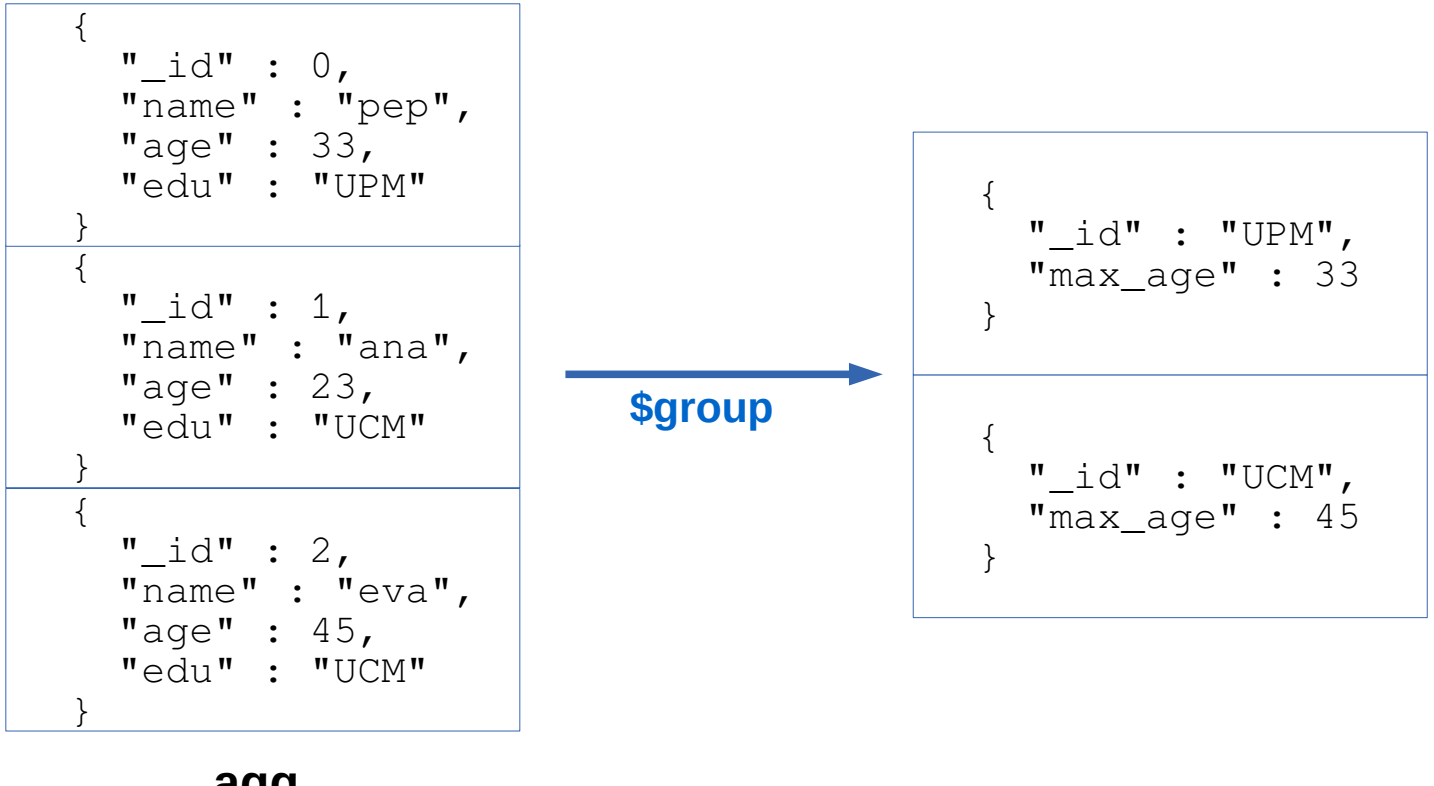

Ejemplo de $group

- Calcular la **edad media** y el **número de alumnos** por **Universidad**:

```
db.agg.aggregate([
   $group: {_id: "$edu",
            avg_age: {$avg:"$age"}, count: {$sum:1} }}
])
```

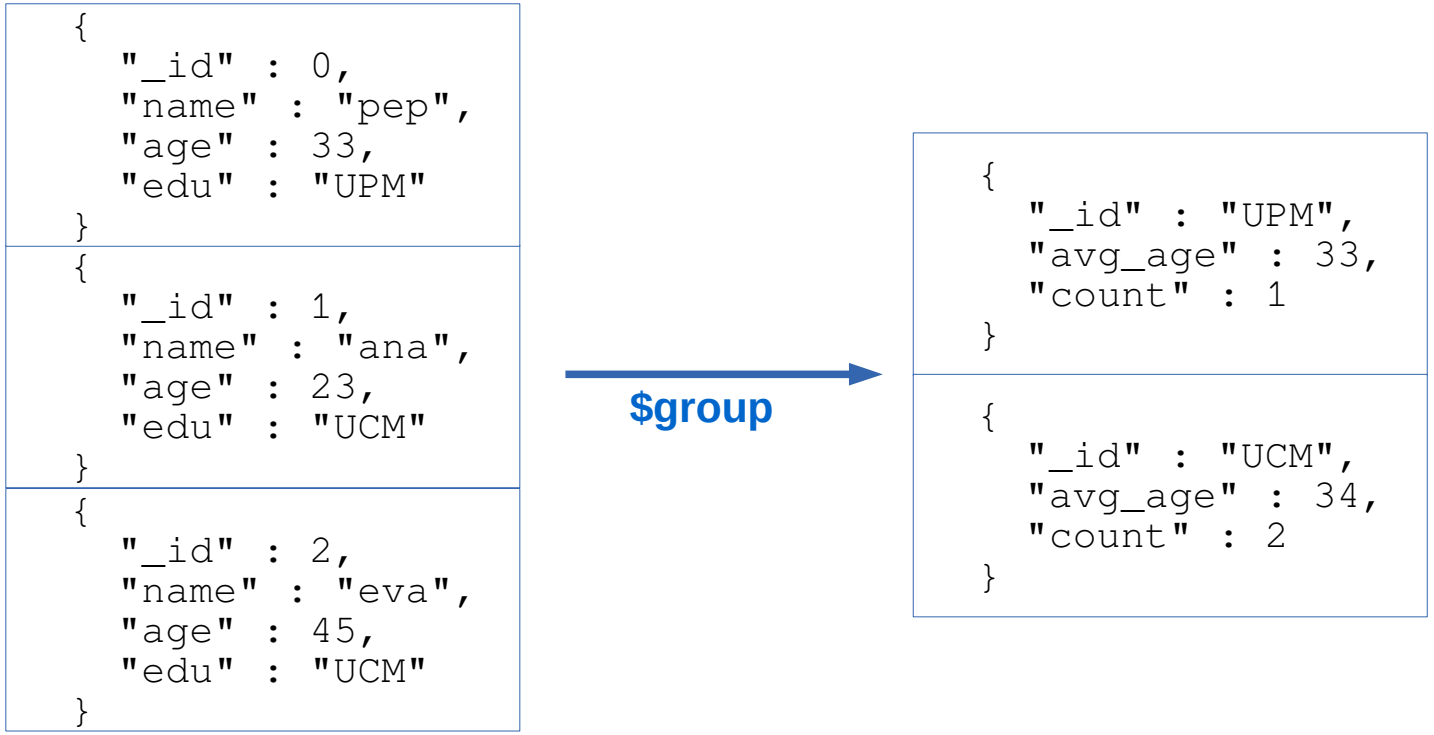

Ejemplo de $group

- Obtener los nombres de los **alumnos** de cada **Universidad** en un único documento:

```
db.agg.aggregate([
      {$group: {_id: "$edu",
                names:{$push:"$name"} }}
])
```

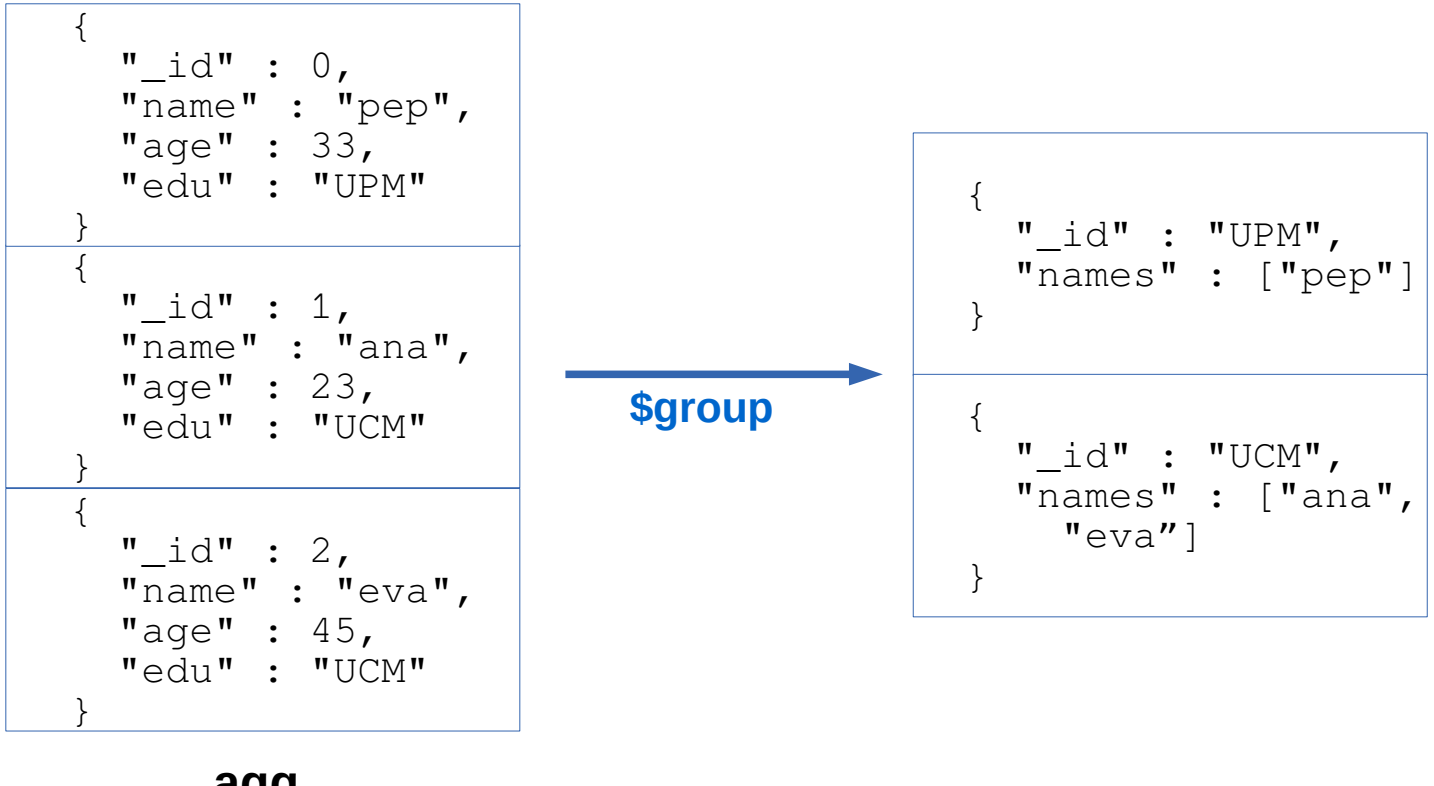

$lookup

- La etapa $lookup realiza una combinación externa izquierda ***(left outer join)*** de los documentos de entrada con otra colección.
- La combinación se realiza comparando dos campos de los documentos que pueden tener un **nombre diferente**: uno de la colección **local** y otro de la **externa**.
- El documento de la colección se **extiende** con una **lista** conteniendo los documentos de la otra colección que tienen el mismo valor en el campo.

$lookup

- La sintaxis de la etapa $lookup es:

{ $lookup: {
from: <colección externa a combinar>**,**
localField: <nombre del campo de los docs. de la colección local a comparar>**,**
foreignField: <nombre del campo de los docs. de la colección externa a comparar**>,**
as: <nombre del campo generado que almacenará la lista>

} }

Ejemplo de $lookup

- Combinar usuarios con sus pedidos:

```
db.users.aggregate([
  $lookup: { from : "orders",
             localField : "dni",
             foreignField : "user",
             as : "pedidos"} }
])
```

```
{
  "_id" : 0,
  "dni" : "125G",
  "name" : "ana"
}
{
  "_id" : 1,
  "dni" : "845K",
  "name" : "pep"
}
```

users

```
{
  "_id" : 0,
  "user" : "125G",
  "total" : 87651
}
{
  "_id" : 1,
  "user" : "125G",
  "total" : 4562
}
```

orders

$lookup

```
{
  "_id" : 0,
  "dni" : "125G",
  "name" : "ana",
  "pedidos":[
    { "_id":0,
      "user" : "125G",
      "total" : 87651},
    { "_id" : 1,
      "user" : "125G",
      "total" : 4562 }]
}
{
  "_id" : 1,
  "dni" : "845K",
  "name" : "pep",
  "pedidos" : []
}
```

$lookup

- El nuevo campo añadido por $lookup contiene una lista con los documentos **completos** que encajan.
- Este nuevo campo puede ser una **lista vacía** si en la colección externa no hay ningún documento que encaje.
- La colección externa debe pertenecer a la **misma base de datos**.

$out

- La etapa $out **almacena** los documentos en un **colección**.
- La colección de salida se **crea** si no existe, y si existe se **reemplaza completamente**.
- La sintaxis de $out es:
  { $out: <colección de salida> **}**

$out

- La etapa $out fallará si existen documentos con el campo **_id** duplicado.
- Si los documentos carecen de _id, éste campo será **generado automáticamente**.
- La etapa $out debe ser la **última de la tubería**.
- Ejemplo: volcar los resultados en la colección **summary**:

```
> db.users.aggregate([
    …, // Etapas anteriores
    { $out : “summary”}
]}
```

Conectar tuberías

Conectando tuberías

- Hasta ahora hemos visto ejemplos de tuberías de una sola etapa, que toman la entrada directamente de una colección.
- La potencia del *aggregation pipeline* consiste en **combinar etapas**.
- Para ello solo es necesario definir las etapas en el orden deseado.

Ejemplos de tuberías

- Universidades con 2 o más alumnos:

```
db.students.aggregate([
   {$group : {"_id":"$edu", "num":{$sum:1}}},
   {$match : {"num":{$gte:2}}}
])
```

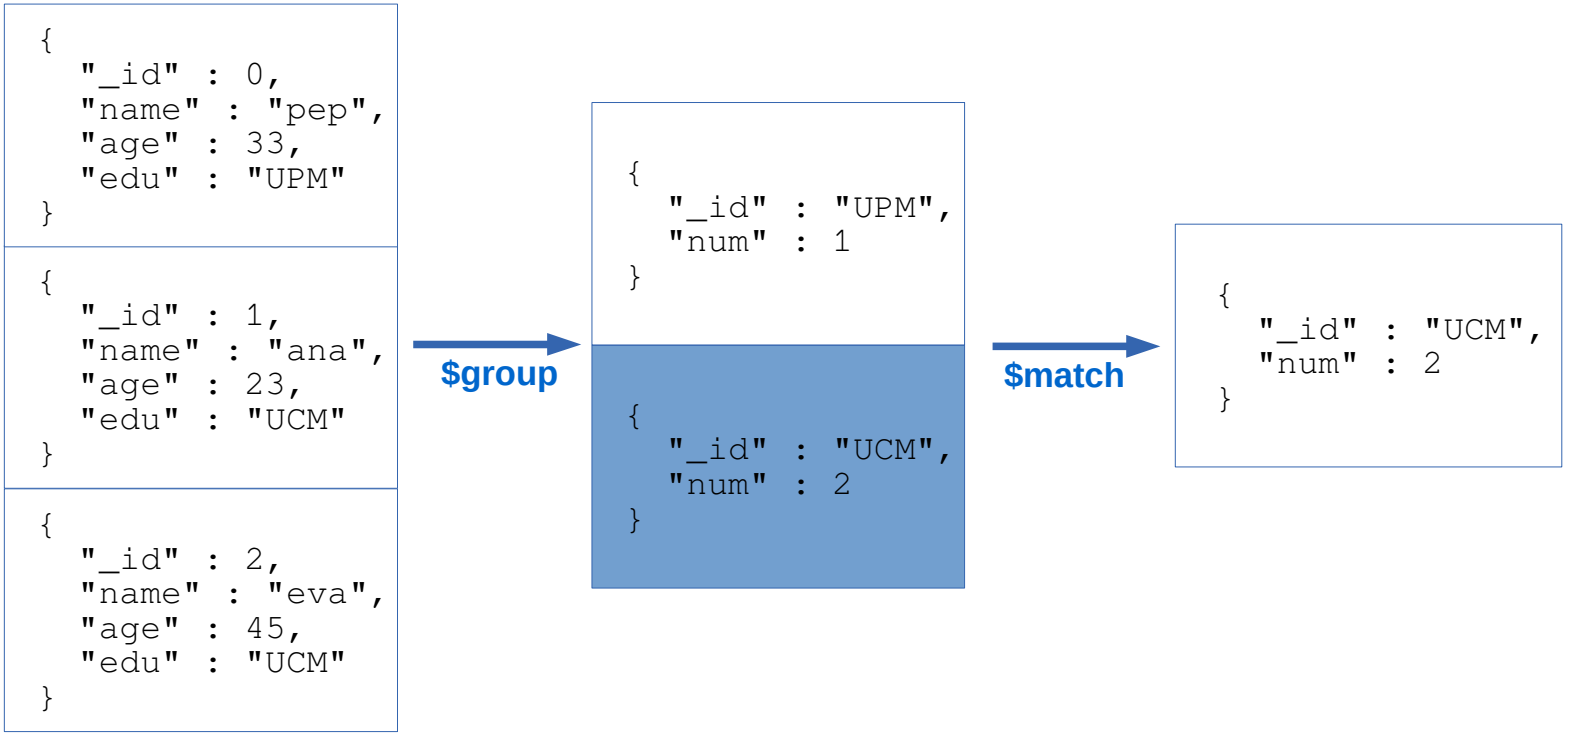

Ejemplos de tuberías

- Universidad que tiene más alumnos:

```
db.students.aggregate([
   {$group : {"_id":"$edu", "num":{$sum:1}}},
   {$sort : {"num" : -1}},
   {$limit : 1},
])
```

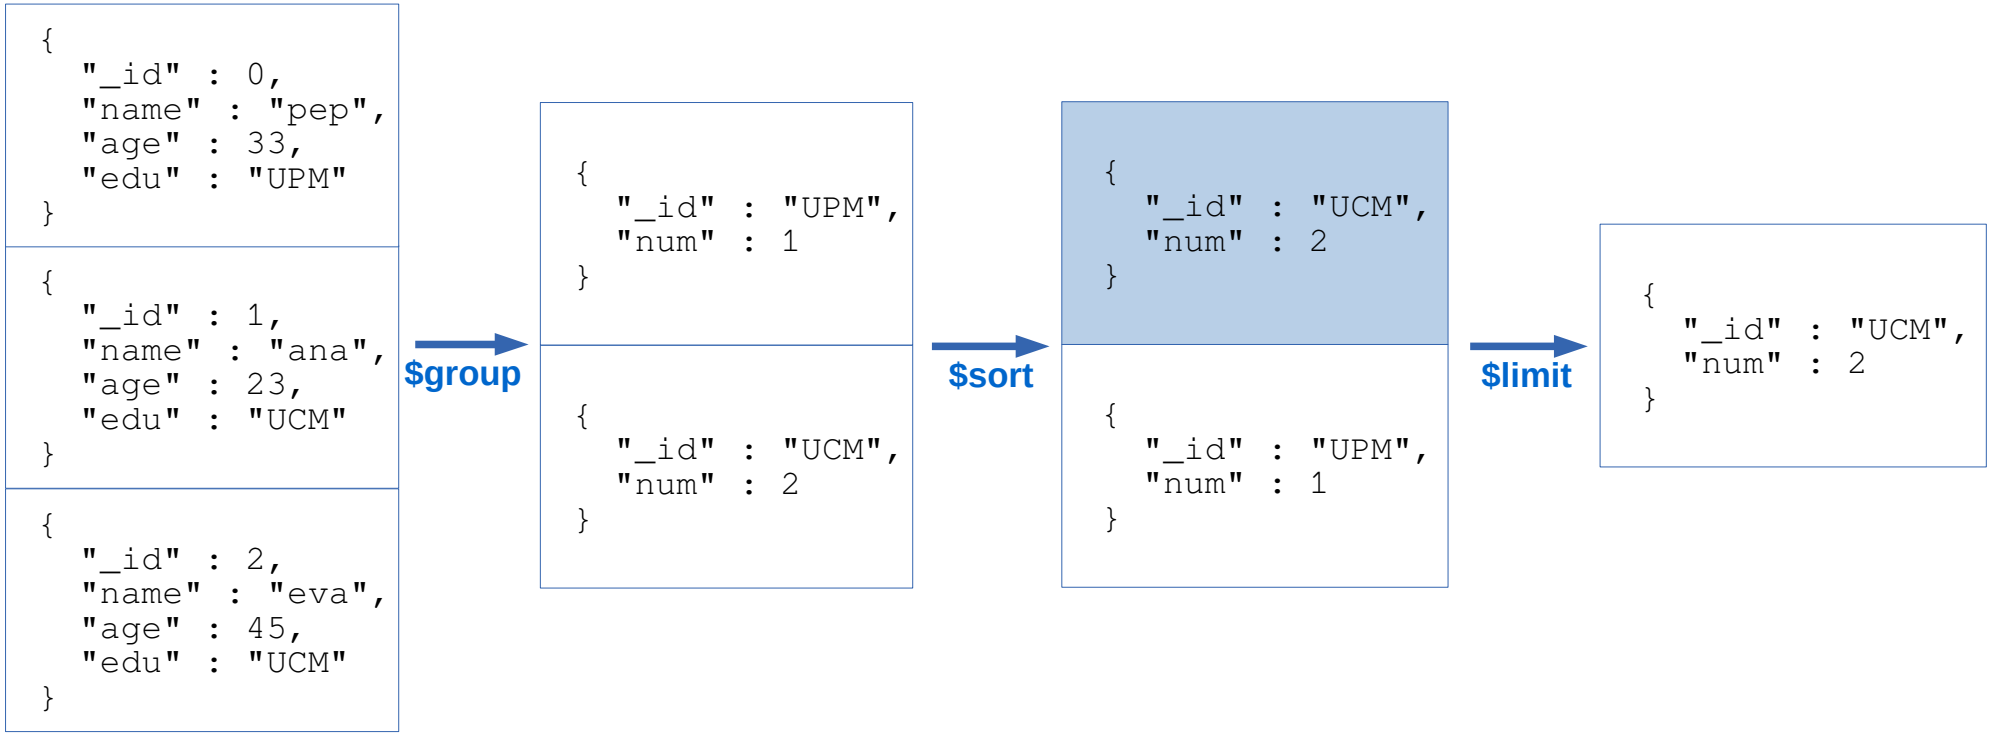

Ejemplos de tuberías

- Frecuencia de cada número:

```
db.students.aggregate([
   {$unwind:"$nums"},
   {$group: {"_id":"$nums", "freq":{"$sum":1}}}
])
```

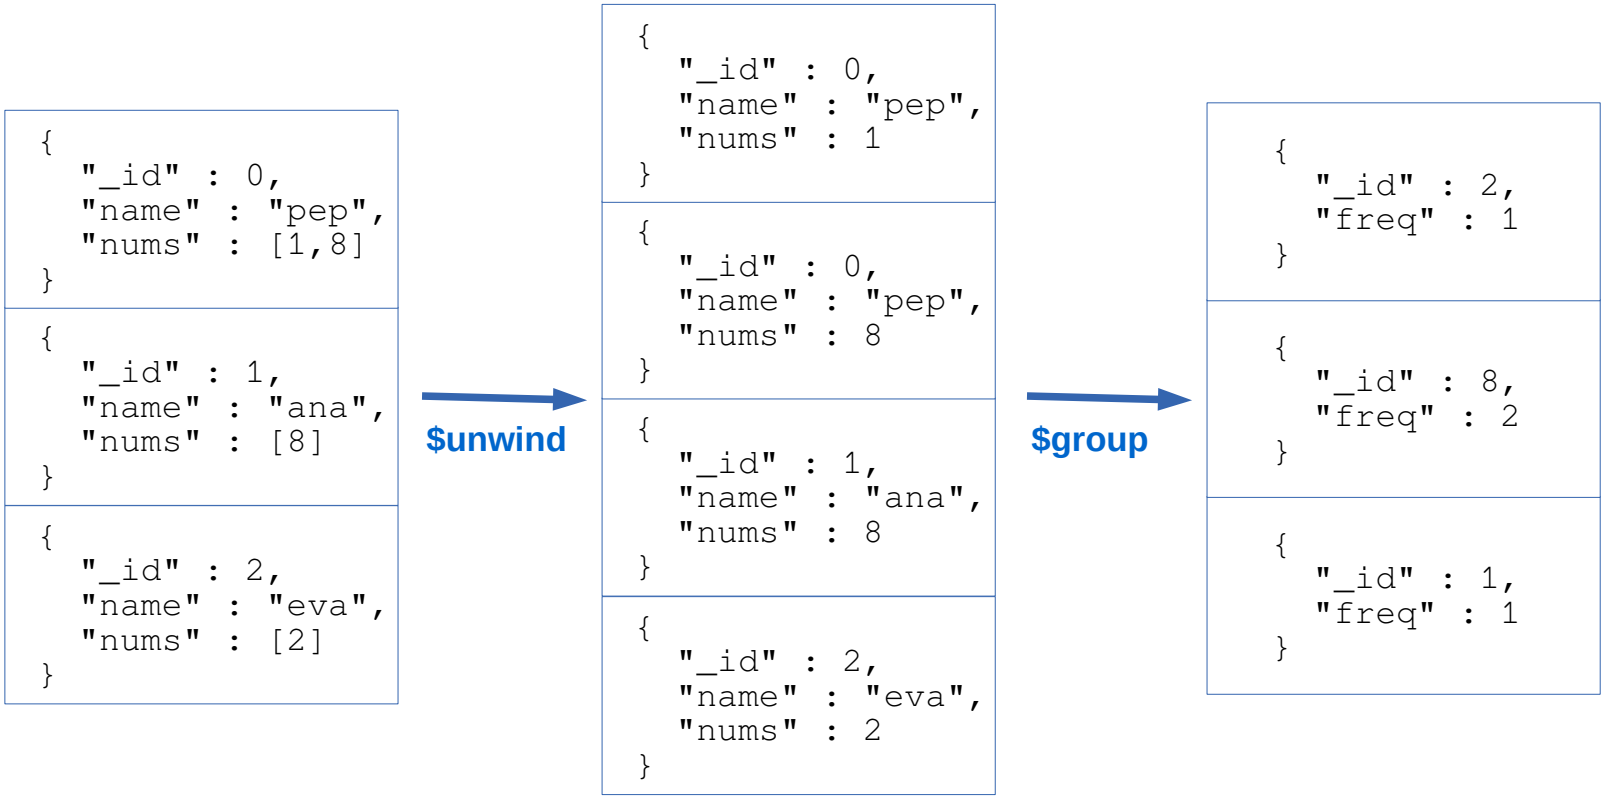

Ejercicios

Ejercicio 1

- **Nombre** de la universidad con mayor edad media, dentro del campo “univ”.

```
{
  "_id" : 0,
  "name" : "pep",
  "age" : 33,
  "edu" : "UPM"
}
```

```
{
  "_id" : 1,
  "name" : "ana",
  "age" : 23,
  "edu" : "UCM"
}
```

```
{
  "_id" : 2,
  "name" : "eva",
  "age" : 45,
  "edu" : "UCM"
}
```

students

```
{
  "univ" : "UCM"
}
```

Resultado esperado

Ejercicio 2

- Listado de **números más frecuentes** y **lista de usuarios, ordenados** por:
  1. número de apariciones, descendente
  2. número, descendente

```
{
  "_id" : 0,
  "name" : "pep",
  "nums" : [1,8]
}
{
  "_id" : 1,
  "name" : "ana",
  "nums" : [8]
}
{
  "_id" : 2,
  "name" : "eva",
  "nums" : [2]
}
```

students

```
{
  "_id" : 8,
  "freq" : 2
  "users" : [0, 1]
}
{
  "_id" : 2,
  "freq" : 1
  "users" : [2]
}
{
  "_id" : 1,
  "freq" : 1
  "users" : [0]
}
```

Resultado esperado

Ejercicio 3

- **Usuarios** junto con el **número de pedidos** que han realizado (sin usuarios con 0 pedidos).

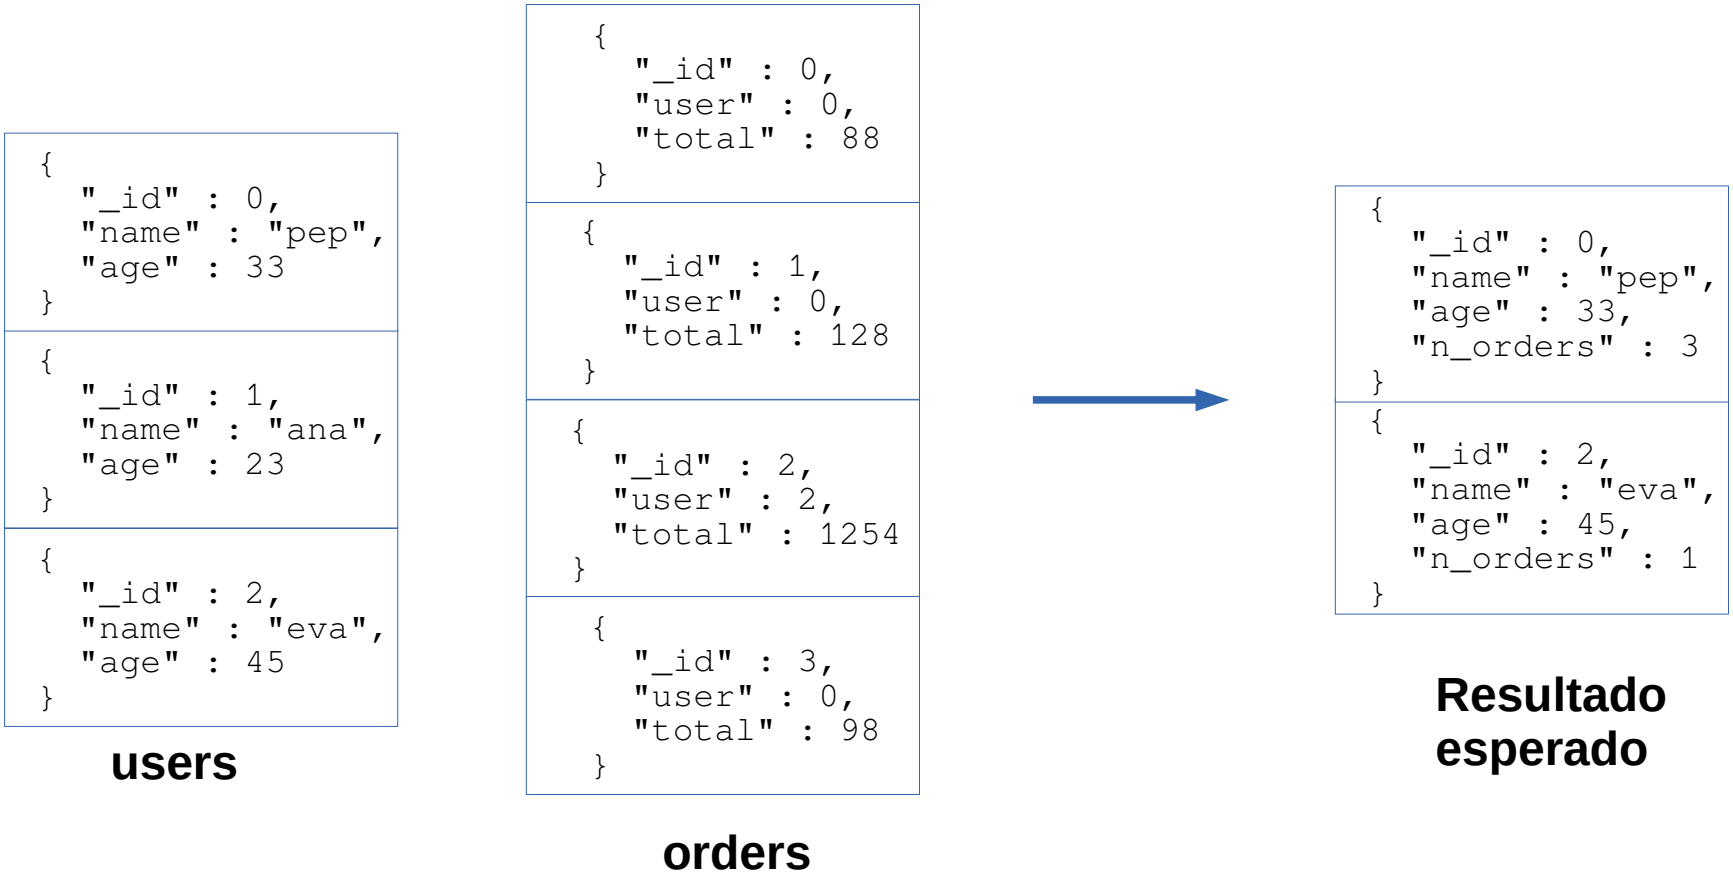

Ejercicio 4

- **Usuarios** junto con **gasto total** de sus compras, sólo si han gastado más de 1000€. Ordenados de manera descendente por gasto total.

```
{
  "_id" : 0,
  "name" : "pep",
  "age" : 33
}
{
  "_id" : 1,
  "name" : "ana",
  "age" : 23
}
{
  "_id" : 2,
  "name" : "eva",
  "age" : 45
}
```

users

```
{
  "_id" : 0,
  "user" : 0,
  "total" : 88
}
{
  "_id" : 1,
  "user" : 0,
  "total" : 128
}
{
  "_id" : 2,
  "user" : 2,
  "total" : 1254
}
{
  "_id" : 3,
  "user" : 0,
  "total" : 98
}
```

orders

```
{
  "_id" : 2,
  "name" : "eva",
  "age" : 45,
  "total" : 1254
}
```

Resultado esperado

Tuberías de agregación en pymongo

aggregate()

- Los objetos **Collection** de pymongo tienen un método **aggregate** (ver detalles en referencias).
- El método aggregate() recibe una **lista Python de etapas** representadas como diccionarios.
- La sintaxis de cada etapa es **exactamente igual** a la usada en la **consola** de MongoDB.

aggregate()

```
from pymongo import MongoClient

mongoclient = MongoClient()
db = mongoclient['giw']
c = db['users']

c.insert_one({'name':'ana', '_id':0, 'edad':24})
c.insert_one({'name':'eva', '_id':1, 'edad':28})
c.insert_one({'name':'pep', '_id':2, 'edad':34})

r = c.aggregate(  [
    {'$match':{'edad':{'$gt':25}} },
    {'$sort':{'edad':-1}}
])

for e in r:
    # procesar e
```

Referencias

Documentación de MongoDB

- Todas las etapas del ***aggregation pipeline:***
  https://docs.mongodb.com/manual/reference/operator/aggregation/#aggregation-pipeline-operator-reference
- Etapa **$project**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/project/#pipe._S_project
- Etapa **$match**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/match/#pipe._S_match

Documentación de MongoDB

- Etapa **$sort**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/sort/#pipe._S_sort
- Etapa **$limit**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/limit/#pipe._S_limit
- Etapa **$skip**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/skip/#pipe._S_skip

Documentación de MongoDB

- Etapa **$unwind**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/unwind/#pipe._S_unwind
- Etapa **$group**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/group/#pipe._S_group
- Etapa **$lookup**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/lookup/#pipe._S_lookup

Documentación de MongoDB

- Etapa **$out**:
  https://docs.mongodb.com/manual/reference/operator/aggregation/out/#pipe._S_out
- Método **aggregate()** de pymongo:
  https://api.mongodb.com/python/current/api/pymongo/collection.html#pymongo.collection.Collection.aggregate